

Project Report: “基于 LSTM 和注意力机制的多变量时间序列预测 - 共享单车使用量分析”

1.1 项目概述

项目标题: 基于 LSTM 和注意力机制的多变量时间序列预测 - 共享单车使用量分析

研究背景:

共享单车系统作为城市交通的重要组成部分,其需求预测对于运营优化、车辆调度和资源分配至关重要。准确预测单车使用量可以帮助运营商减少空车率,提高服务质量,同时降低运营成本。

项目目标:

开发一个结合 LSTM 和注意力机制的深度学习模型,利用历史使用数据和环境因素(气温、湿度、风速等)以及时间特征,准确预测未来时间点的单车使用量。

1.2 数据分析

数据集描述:

数据来源: BikeShares.csv

时间范围: 包含时间戳的连续记录

特征维度: 11 个原始特征 + 4 个周期特征

样本数量: 未明确显示但通过 shape 可获取

关键字段:

目标变量: cnt (租用共享单车的数量)

数值特征: t1(气温), t2(体感温度), hum(湿度), wind_speed(风速)

分类特征: weather_code, is_holiday, is_weekend, season

时间特征: hour_sin, hour_cos, dayofweek_sin, dayofweek_cos

可视化分析:

气温与使用量关系: 点图显示温度与使用量呈非线性关系

季节影响: 点图显示不同季节的使用模式差异明显

假期影响: 线图显示工作日与假期的使用模式对比

天气影响: 不同天气条件下的使用量分布

数据预处理:

时间特征工程: 添加周期时间特征(sin/cos 编码)

特征归一化: 使用 RobustScaler 处理数值特征

数据集划分: 按时间顺序划分训练集(80%)和测试集(20%)
序列构造: 10 个时间步长的滑动窗口构造时间序列样本

1.3 方法论

模型架构:

输入层: 接受形状为(10, 15)的输入(10 个时间步, 15 个特征)

第一 LSTM 层: 128 个单元, 返回完整序列

层归一化与 Dropout(0.3)

多头注意力机制: 4 个头, key 维度 64

第二 LSTM 层: 64 个单元

时间注意力层: 自注意力机制

全局平均池化

全连接层: 32 个 ReLU 单元

输出层: 1 个线性单元

创新点:

周期时间特征编码: 使用 sin/cos 函数编码小时和星期特征

混合架构: 结合 LSTM 的时序处理能力和注意力机制的特征重要性加权

动态学习率调整: 指数衰减学习率策略

双重注意力机制: 多头注意力+时间注意力

训练配置:

损失函数: MSE

优化器: Adam with exponential decay (初始 lr=0.001)

批大小: 128

早停策略: 监控 val_loss, 耐心值 15

模型检查点: 保存最佳模型

学习率调整: 当 val_loss 停滞时减少学习率

1.4 实验结果

训练过程:

训练/验证损失曲线显示良好收敛

早停机制有效防止过拟合

动态学习率调整帮助模型跳出局部最优

评估指标:

R^2 分数: 具体数值需查看训练输出(代码中显示计算但未明确数值)

残差分析: 残差分布接近正态, 无明显模式

预测可视化: 前 200/300 个样本的预测值与真实值对比显示良好拟合

模型诊断:

残差标准差分析确认无过拟合

注意力权重可视化(可考虑添加)可解释重要特征

1.5 结论与展望

结论:

混合架构有效捕捉了时间序列的长期依赖和特征重要性

周期特征编码显著提升了模型对时间模式的理解

注意力机制帮助模型聚焦关键时间点和特征

改进方向:

添加外部特征(如节假日事件、促销活动)

尝试 **Transformer** 架构的纯注意力模型

开发多任务学习框架(同时预测使用量和需求热点)

实现在线学习以适应使用模式变化

应用建议:

实时需求预测系统

动态定价策略优化

车辆再平衡调度算法

异常检测(使用量异常波动预警)